CBNU

강화학습 week6

SARSA, Q-Learning

지능로봇공학과 김민재 2021042040

Contents

1. 환경과 알고리즘

- 5×5 Grid World 의 보상 · 종료 규칙
- SARSA, Q-Learning 의 갱신식

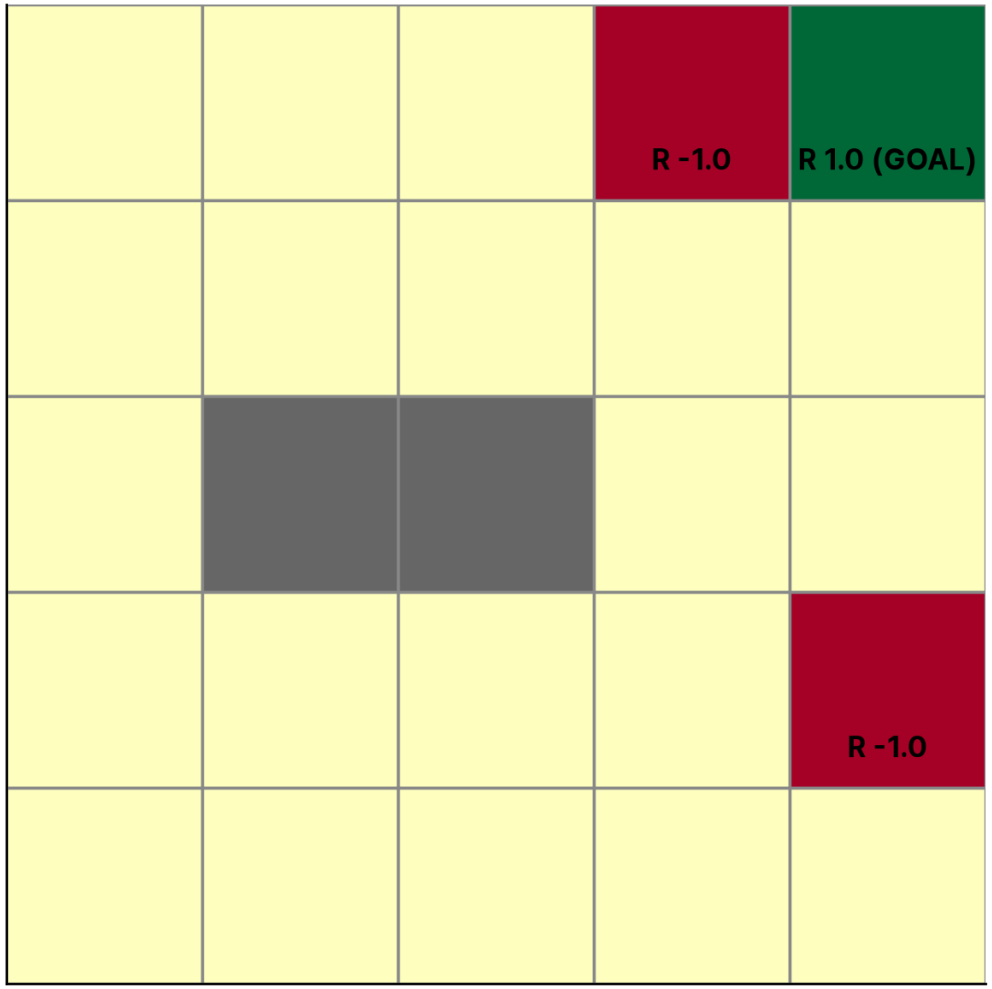
2. 코드와 학습 결과

- SARSA, Q-Learning 의 핵심 코드
- 학습 곡선 · Q-value · 정책 비교

3. 어블레이션 실험

- Episode · ε · α · γ 를 하나씩 변경
- 고정 평가 조건에서 결과 비교

5×5 Grid World · 환경



- 과제의 배치와 환경 규칙

시작 (5,1), 목표 (1,5)
벽 (3,2), (3,3)
폭탄 (1,4), (4,5)

일반 보상 0, 폭탄 – 1, 목표 +1
폭탄에 들어가도 이동을 계속함 .
목표에 도착하면 Episode 종료 .

벽 · 경계 방향으로 움직이면 제자리 .
폭탄을 피하는 최단 경로는 8 steps.
좌표는 행 · 열 , 1 부터 표기함 .

SARSA · On-policy

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha\left[R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)\right]$$

- 다음 행동 A_{t+1} 을 ε-greedy 로 선택
  실제로 선택한 행동의 Q 를 갱신 목표에 사용 .

- 행동정책의 기대 할인 보상을 학습
  탐험으로 생기는 손실도 Q 갱신에 반영 .

- 목표 도착 시 다음 Q 는 0
  새 5×5 코드에 원본의 SARSA 갱신식을 적용 .

Q-Learning · Off-policy

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t)]$$

- 다음 상태에서 가능한 행동의 최대 Q 사용
  행동은 ε-greedy 로 선택하고 갱신 목표는 Greedy 로 계산 .

- 탐험과 학습 목표를 분리
  충분히 방문한 상태 · 행동의 최적 Q 를 학습 .

- 목표 도착 시 다음 Q 는 0
  새 5×5 코드에 원본의 Q-Learning 갱신식을 적용 .

어블레이션 · 실험 설계

실험	변경하는 변수	고정하는 학습 조건
기본 설정	변경 없음	E=10,000 · ε=0.1 · α=0.8 · γ=0.9
학습량	Episode 수	ε=0.1 · α=0.8 · γ=0.9
탐험률	ε	E=10,000 · α=0.8 · γ=0.9
학습률	α	E=10,000 · ε=0.1 · γ=0.9
할인율	γ	E=10,000 · ε=0.1 · α=0.8

- 한 변수씩 변경하고 평가 조건도 고정

- Greedy 평가 : ε=0 · 탐험 평가 : ε=0.1 · 평가 할인율 γ=0.9
- 30 개 시드 반복 · 탐험은 시드별 500 회 · 최대 1,000 steps

SARSA · 핵심 코드

```
# train_one 의 핵심 갱신 과정을 요약
nxt = ns[s, a]
r = rewards[s, a]
done = dones[s, a]


next_a = 0
if not done:
    next_a = select_action(q, nxt, eps)


target = r
if not done:
    target += gamma * q[nxt, next_a]


q[s, a] += alpha * (target - q[s, a])


if not done:
    s, a = nxt, next_a
```

- 선택한 다음 행동의 Q 를 사용

① ε-greedy 로 next_a 선택
탐험이면 무작위 , 아니면 최대 Q 행동 .

② target 에 q[nxt, next_a] 사용
실제로 선택한 다음 행동의 가치를 반영 .
탐험 행동의 손실도 갱신 목표에 포함 .

③ TD 오차를 α 만큼 Q 에 반영
갱신한 뒤 선택해 둔 next_a 를 실행 .

목표에서는 target=r, 다음 Q 는 0.

Q-Learning · 핵심 코드

```
# train_one 의 핵심 갱신 과정을 요약
nxt = ns[s, a]
r = rewards[s, a]
done = dones[s, a]


target = r
if not done:
    target += gamma * np.max(q[nxt])


q[s, a] += alpha * (target - q[s, a])


if not done:
    s = nxt
    a = select_action(q, s, eps)
```

- 다음 상태의 최대 Q 를 사용

① target 에 np.max(q[nxt]) 사용
다음 상태에서 가장 큰 행동 가치를 선택 .

② TD 오차를 α 만큼 Q 에 반영
목표값 계산에는 탐험 행동을 쓰지 않음 .

③ 실제 다음 행동은 ε-greedy
학습 목표와 행동 선택을 분리 .
전이와 보상 규칙은 SARSA 와 동일 .

목표에서는 target=r, 다음 Q 는 0.

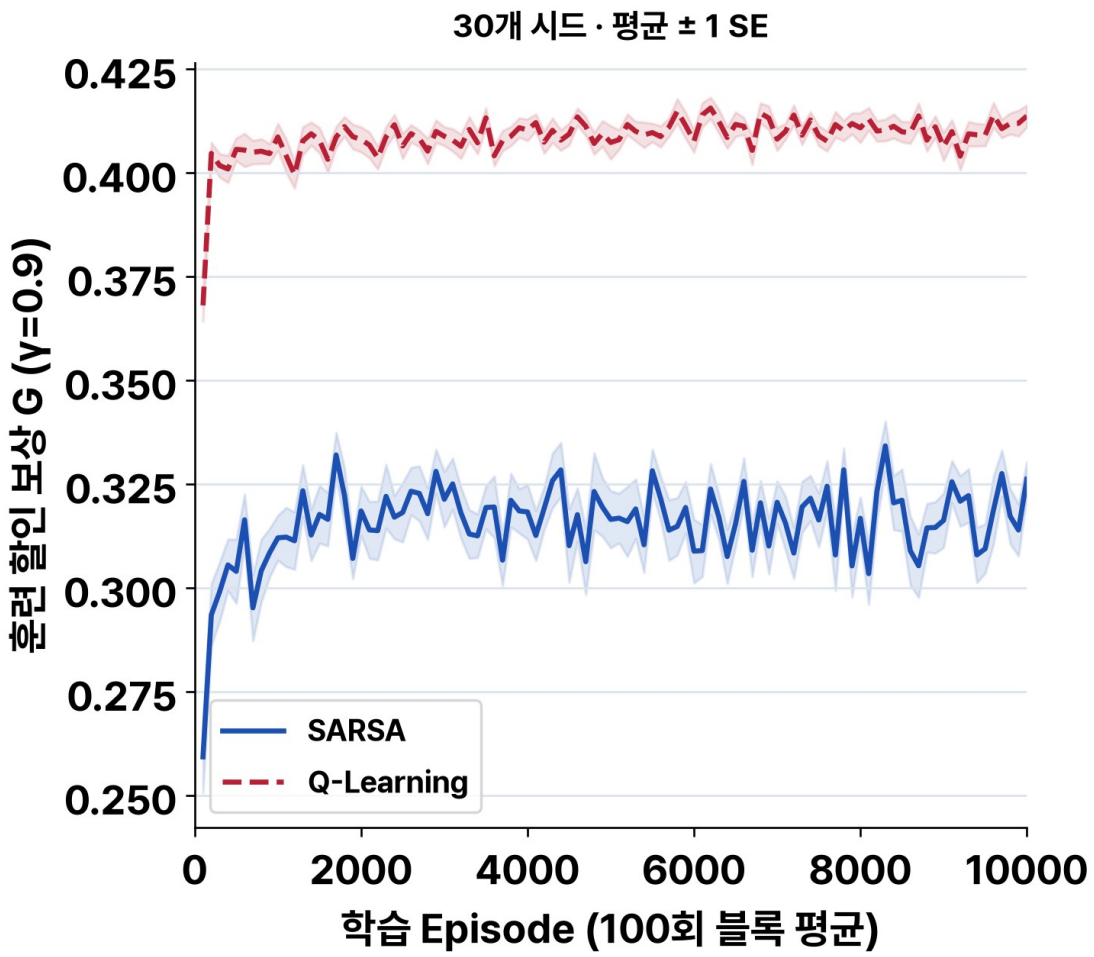
목표 도달 · 기본 설정 비교

평가 지표	SARSA	Q-Learning
Greedy 목표 도달	22/30	30/30
Greedy 8-step 최단 경로	19/30	30/30
탐험 할인 보상 G	0.310 ± 0.150	0.410 ± 0.006
탐험 이동 수 / Episode	25.13 ± 28.16	8.90 ± 0.04
탐험 폭탄 진입 / Episode	0.043 ± 0.018	0.054 ± 0.011

- 고정한 정책과 탐험 중 성능의 차이

• Q-Learning 은 30 개 시드 모두 최단 경로 · 표의 ± 는 시드 간 SD
• SARSA 는 일부 시드에서 순환 · 높은 고정 α 의 영향을 추가 분석

학습 과정 · 할인 보상



- 같은 조건에서 실제 훈련 보상 비교

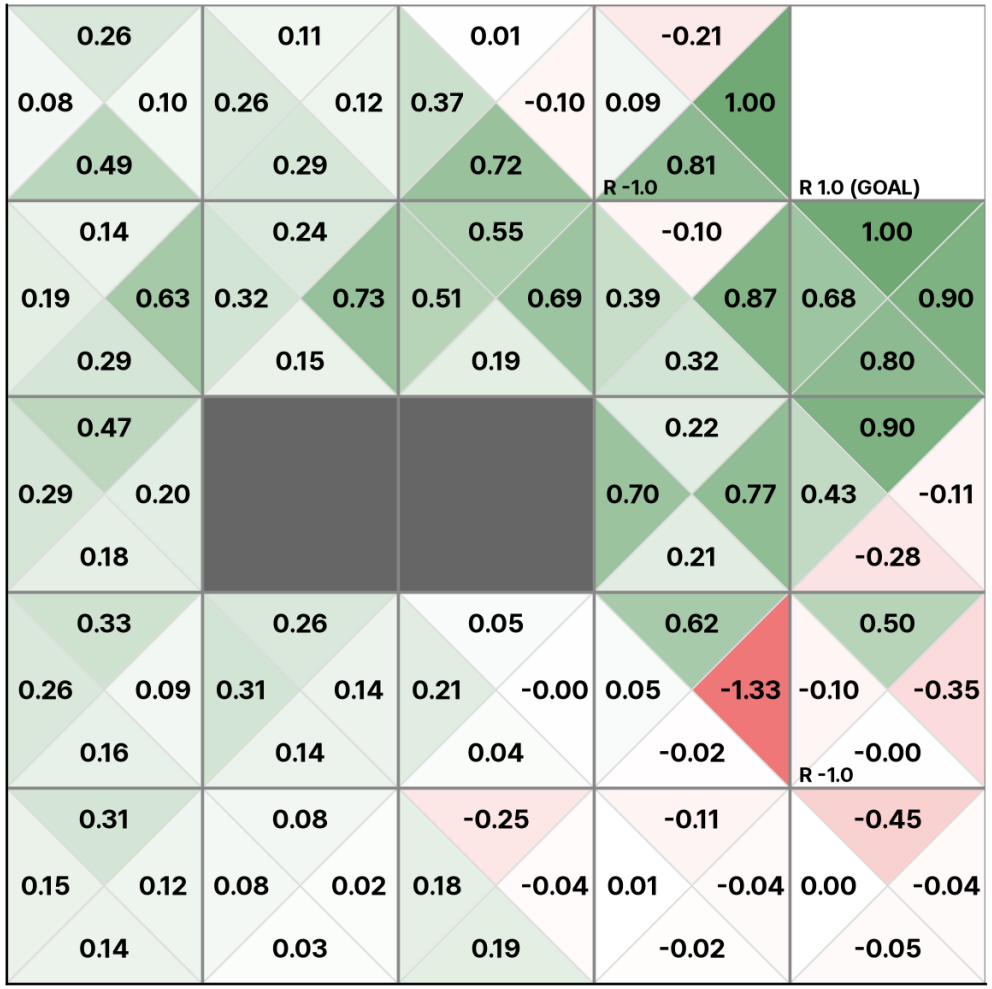
고정 : ε=0.1, α=0.8, γ=0.9
100 Episode 블록 평균 · 실제 훈련 기록

SARSA: 첫 100 회 → 마지막 500 회
할인 보상 G: 0.259 → 0.321

Q-Learning: 같은 구간 비교
할인 보상 G: 0.368 → 0.412

두 방법 모두 초기에 보상이 개선됨 .
후반에는 고정 탐험으로 변동이 남음 .
음영은 30 개 시드 평균의 ±1 SE.

SARSA · Q-value



- 기본 설정의 학습 결과

α=0.8, γ=0.9, ε=0.1
10,000 Episode, 대표 시드 0

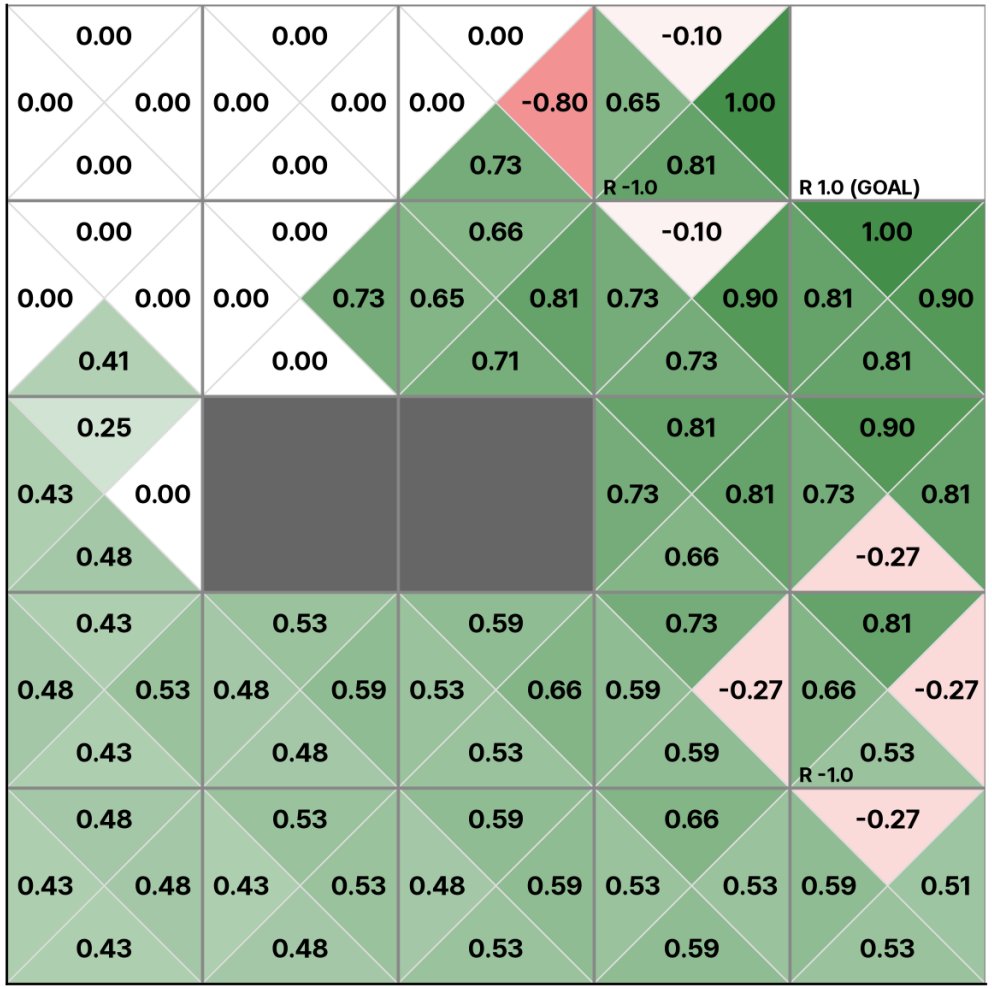
삼각형 : 위 · 아래 · 왼쪽 · 오른쪽 행동 .
양수 Q 는 초록 , 음수 Q 는 붉은색 .
색 범위는 각 그림의 최대 절댓값 기준 .

시작점의 위 행동 Q ≈ 0.309.
탐험이 계속되는 정책의 가치를 학습 .

폭탄 – 1 은 들어갈 때 받는 보상 .
폭탄 칸의 Q 자체가 – 1 인 것은 아님 .

CBNU

Q-Learning · Q-value



- 기본 설정의 학습 결과

α=0.8, γ=0.9, ε=0.1
10,000 Episode, 대표 시드 0

양수 Q 는 초록 , 음수 Q 는 붉은색 .
목표로 바로 가는 행동의 Q 는 1.

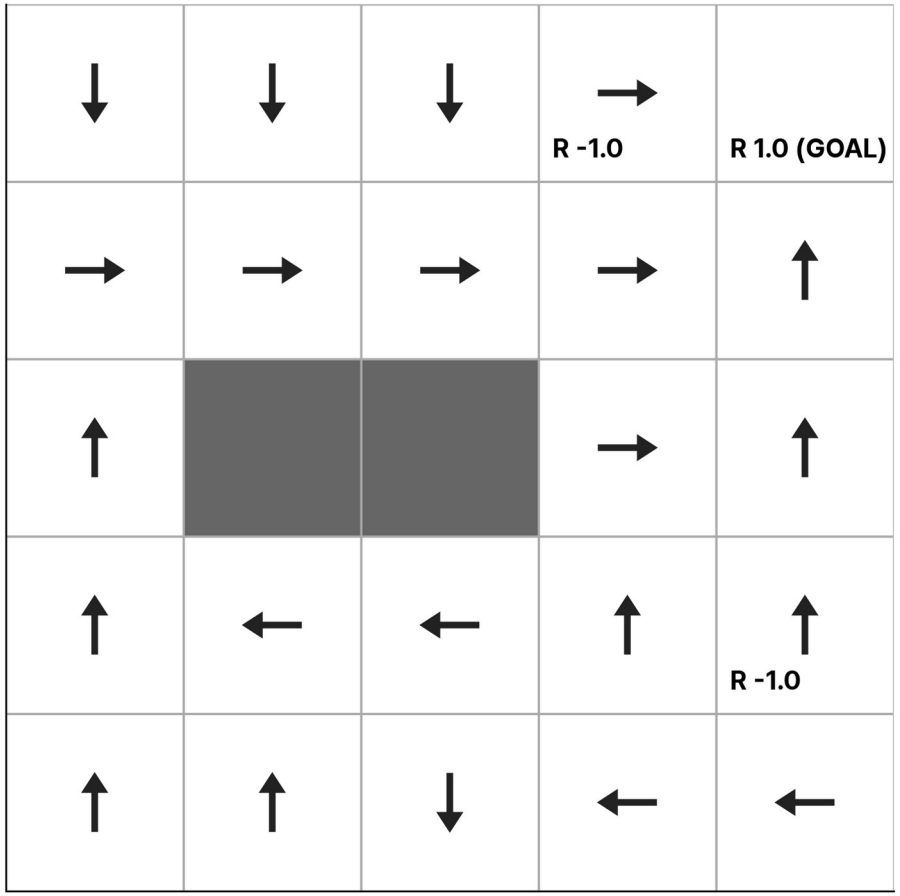
시작점 최대 Q ≈ 0.4783.
8-step 최단 경로의 γ^7 와 일치 .

방문이 적은 칸에는 Q=0 도 남아 있음 .
시작점의 최적 경로를 학습해도
모든 상태 · 행동의 학습 완료는 별개 .

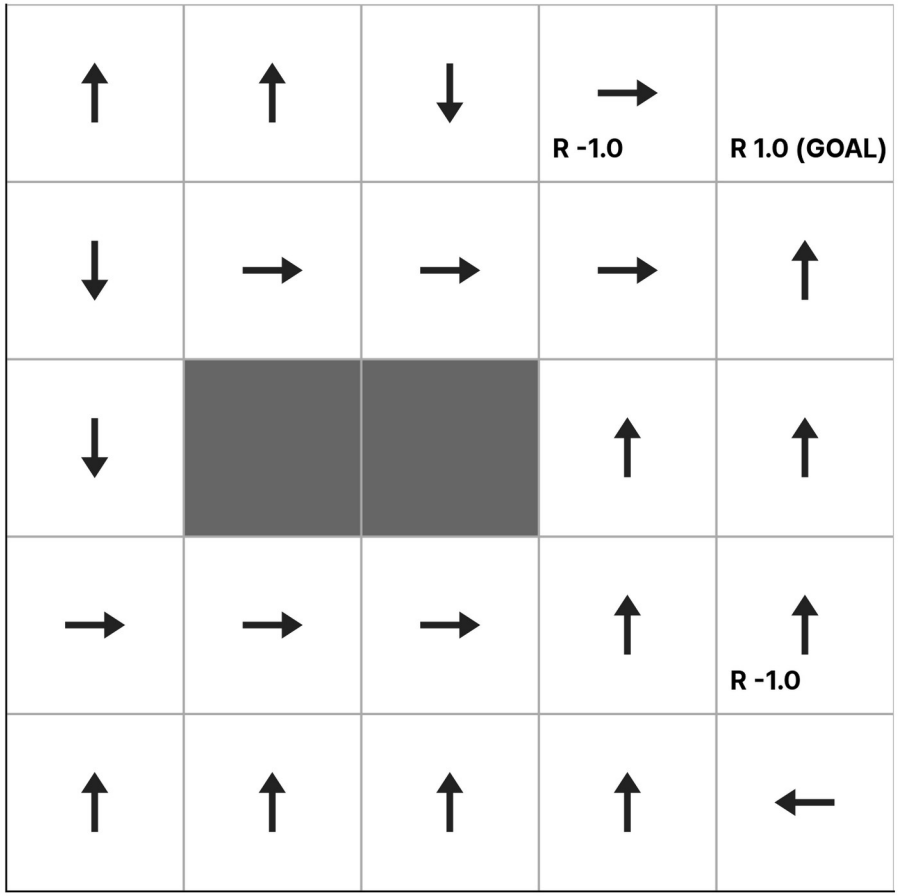
CBNU

Greedy Policy · 대표 시드 0

SARSA · 8 steps



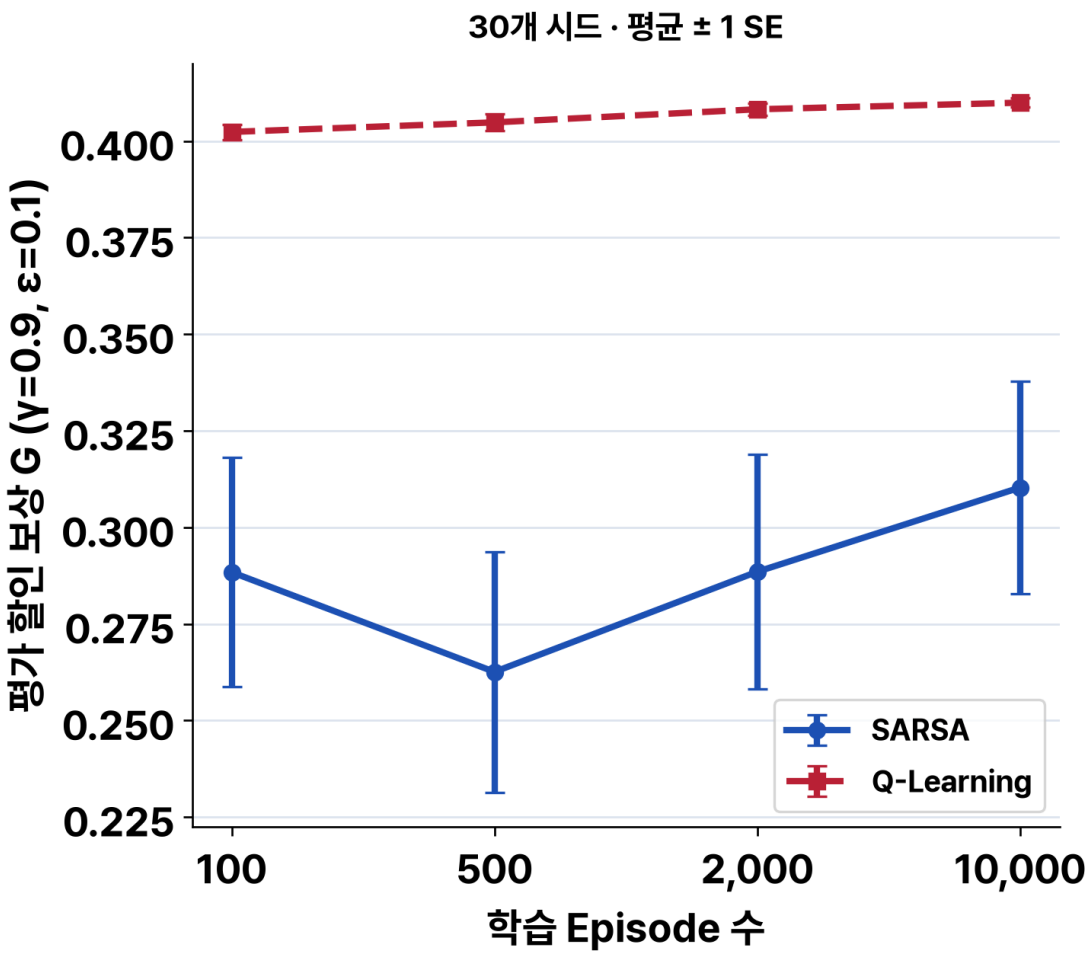
Q-Learning · 8 steps



- 최적 행동 일치 : SARSA 69.1% · Q-Learning 92.0% (22 개 상태 , 30 개 시드 평균)

CBNU

Episode · 학습 어블레이션



- 학습량만 변경 · 실제 평가 보상 비교

변경 : 100, 500, 2,000, 10,000 회

고정 : ε=0.1, α=0.8, γ=0.9

SARSA 의 평가 할인 보상 G:

0.288 → 0.263 → 0.289 → 0.310

Q-Learning 의 평가 할인 보상 G:

0.402 → 0.405 → 0.408 → 0.410

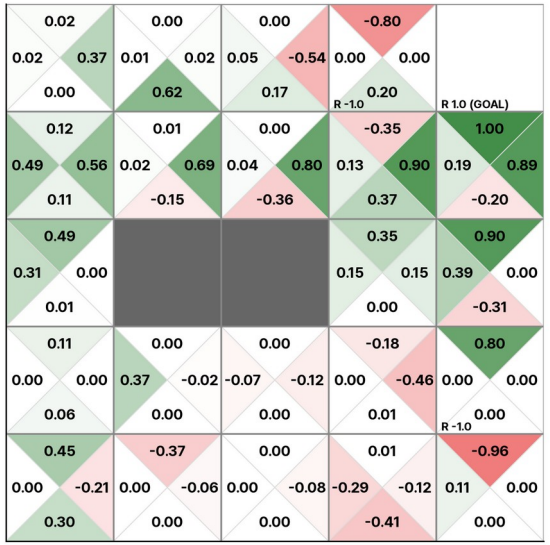
Q-Learning 은 보상이 완만히 증가 .

SARSA 는 학습량에 따른 변동이 관찰됨 .

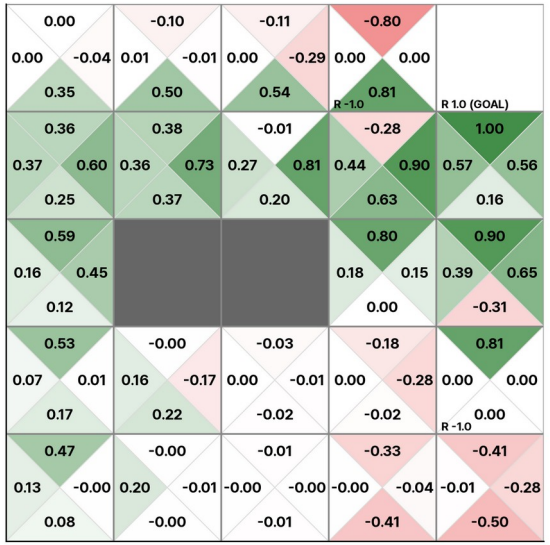
평가 ε=0.1, γ=0.9 로 동일하게 고정 .

SARSA · Episode 어블레이션 · 시드 0

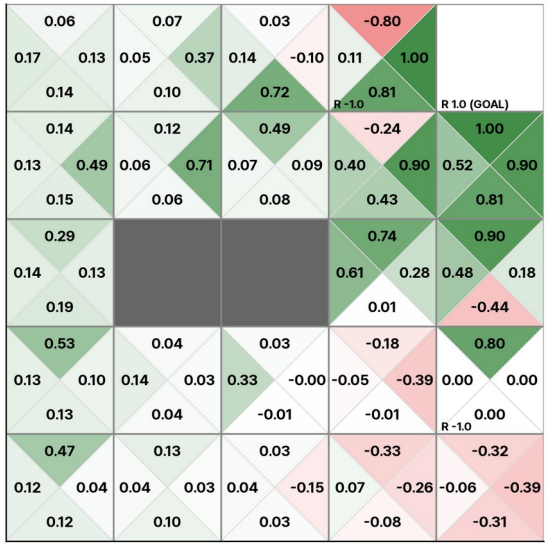
100 Episode



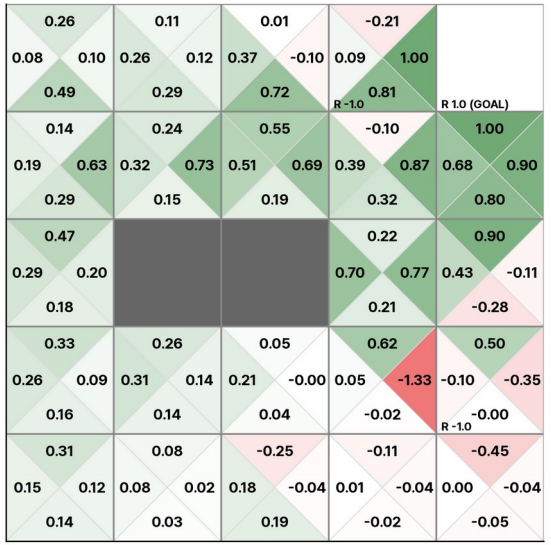
500 Episode



2,000 Episode



10,000 Episode



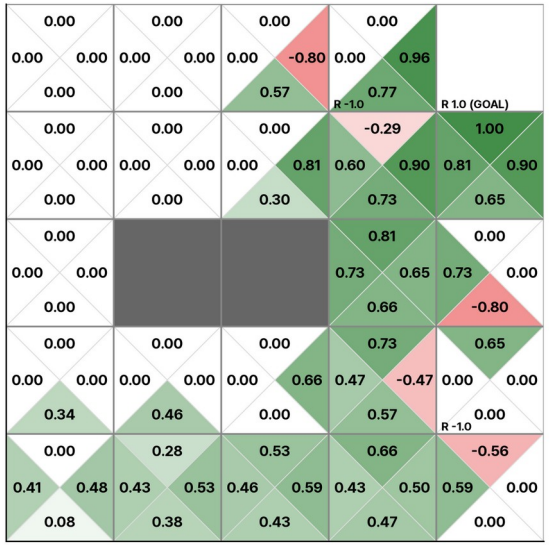
- 학습량이 늘어도 평가 보상은 변동

- 시작점 최대 Q (30 개 시드 평균): 0.272 / 0.364 / 0.353 / 0.340
- 평가 보상 G: 0.288 / 0.263 / 0.289 / 0.310 · 평가 ε=0.1, γ=0.9

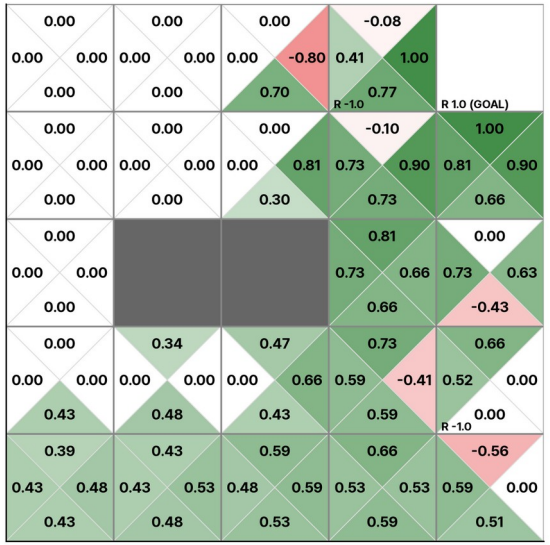
CBNU

Q-Learning · Episode 어블레이션 · 시드 0

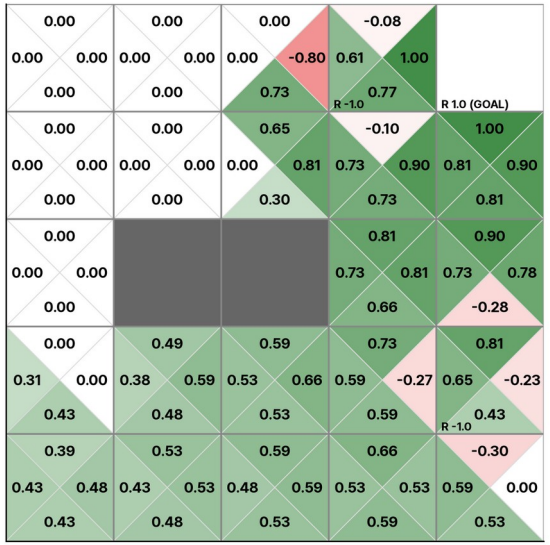
100 Episode



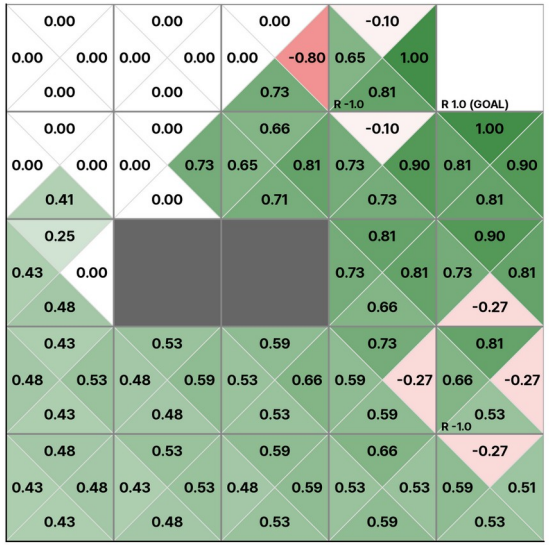
500 Episode



2,000 Episode



10,000 Episode

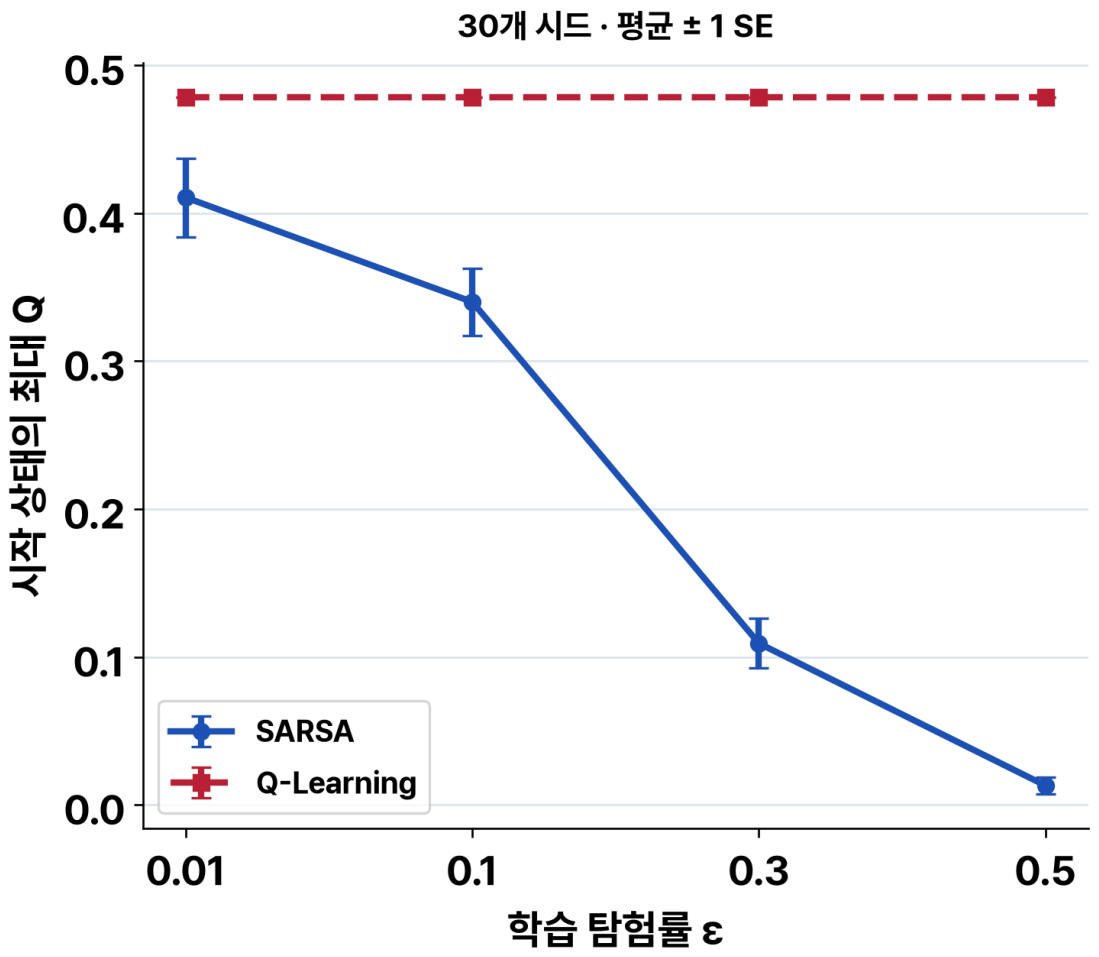


- 추가 학습으로 전체 상태의 정책이 개선

- 시작점 최대 Q (30 개 시드 평균): 0.478 / 0.478 / 0.478 / 0.478
- 평가 보상 G: 0.402 / 0.405 / 0.408 / 0.410 · 평가 ε=0.1, γ=0.9

CBNU

ε · 가치 · 정책 어블레이션



- **탐험률만 변경 · 시작점 Q 비교**

변경 : ε=0.01, 0.1, 0.3, 0.5
고정 : E=10,000, α=0.8, γ=0.9

SARSA 의 평균 최대 Q:
0.411 → 0.340 → 0.109 → 0.013
탐험이 커지면 학습한 가치도 감소 .

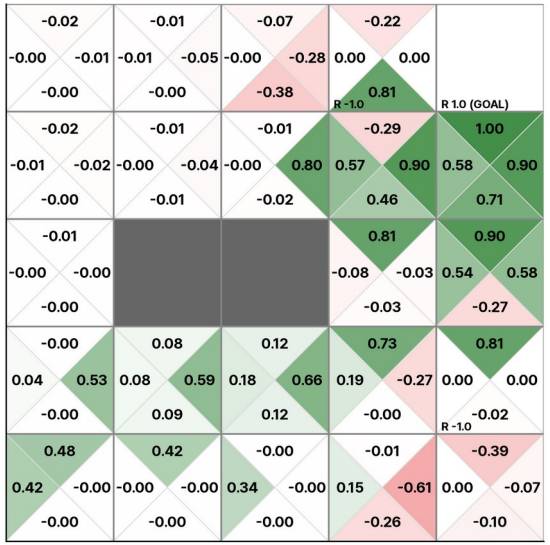
Q-Learning 의 시작점 Q 는 약 0.478.

전체 상태의 최적 행동 일치율 :
Q-Learning: 69.8% → 100%
ε=0.01 → 0.3 에서 방문 범위가 확대됨 .

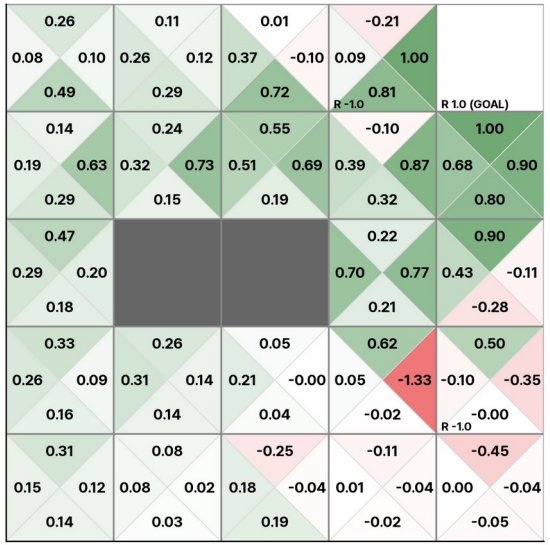
CBNU

SARSA · ε 어블레이션 · 시드 0

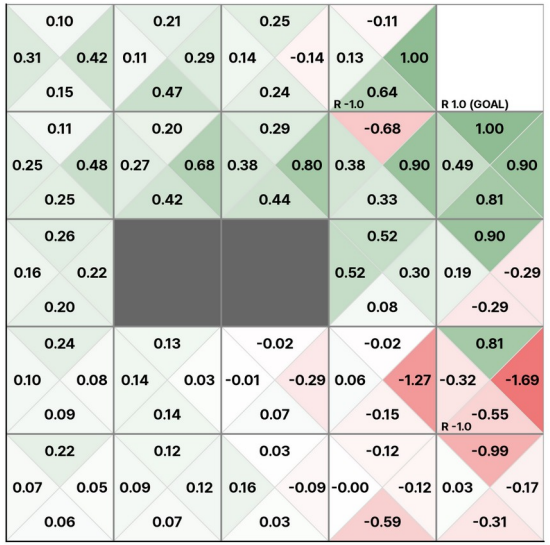
ε=0.01



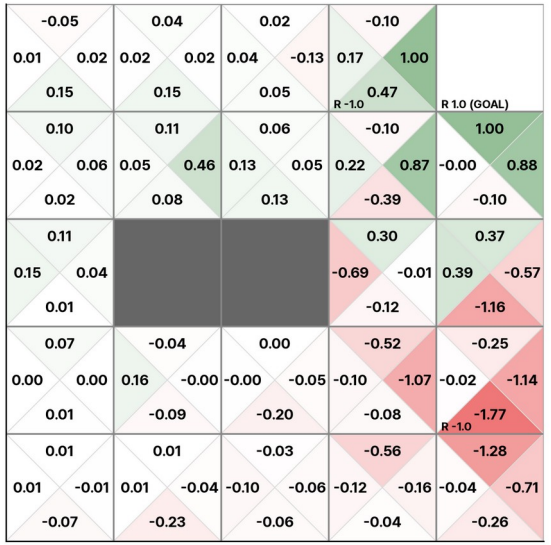
ε=0.1



ε=0.3



ε=0.5



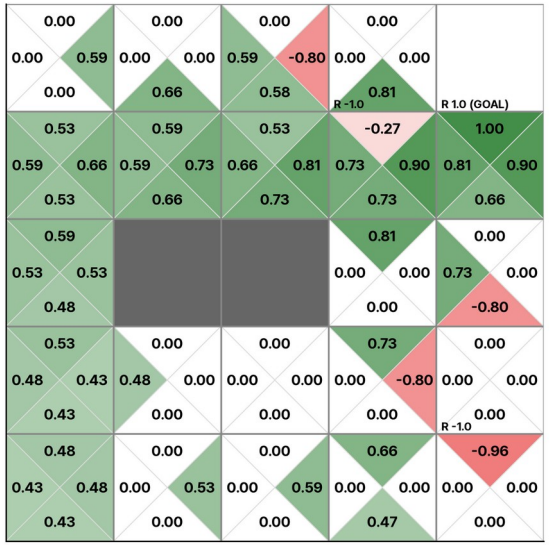
- 탐험률이 커지면 학습한 Q 와 평가 보상이 감소

- 시작점 최대 Q (30 개 시드 평균): 0.411 / 0.340 / 0.109 / 0.013
- 평가 보상 G: 0.363 / 0.310 / 0.176 / 0.027 · 평가 ε=0.1, γ=0.9

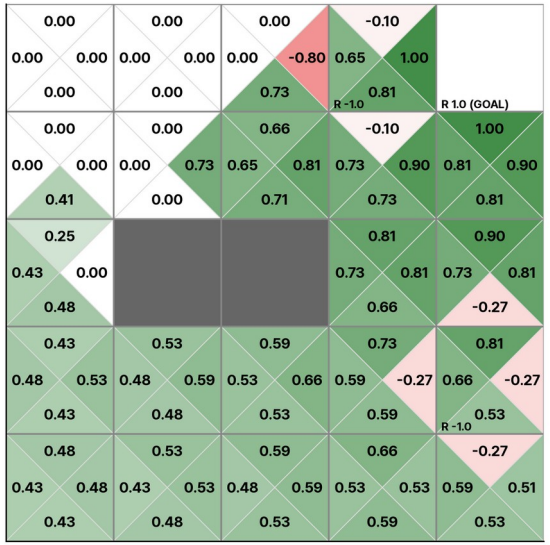
CBNU

Q-Learning · ε 어블레이션 · 시드 0

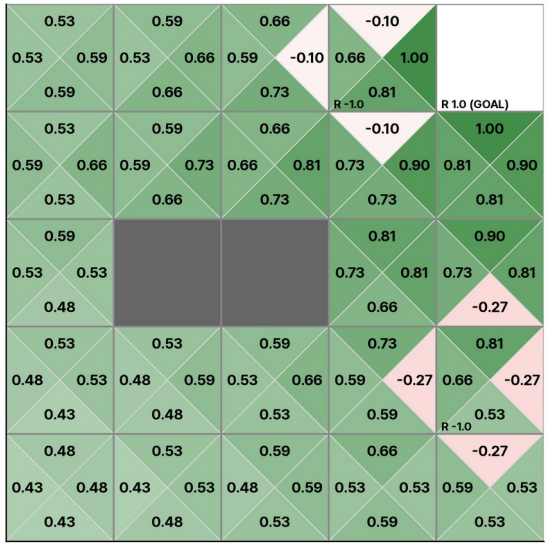
ε=0.01



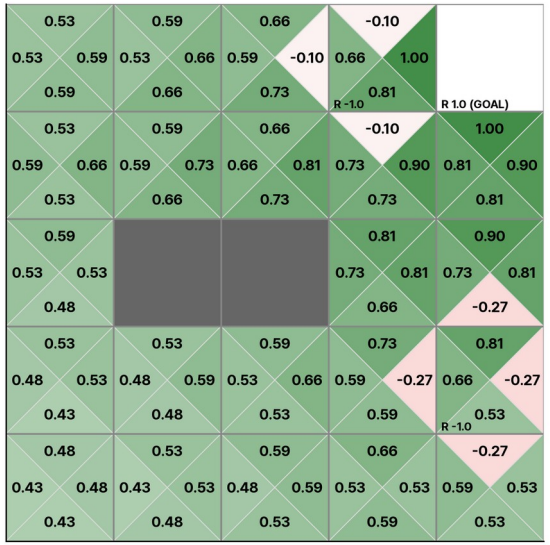
ε=0.1



ε=0.3



ε=0.5

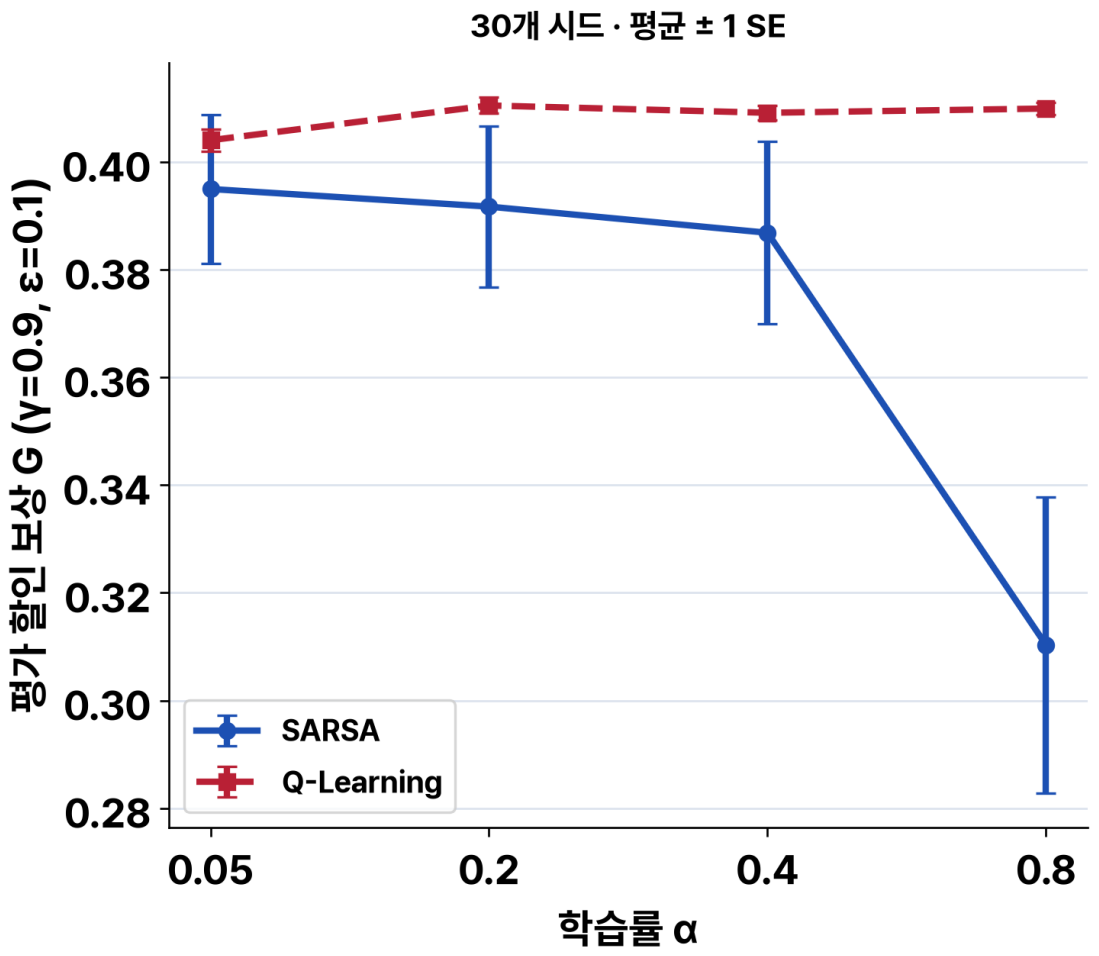


- ε=0.3, 0.5 에서 최적 행동 일치 100%

- 시작점 최대 Q (30 개 시드 평균): 0.478 / 0.478 / 0.478 / 0.478
- 평가 보상 G: 0.404 / 0.410 / 0.414 / 0.414 · 평가 ε=0.1, γ=0.9

CBNU

α · 학습 · 정책 어블레이션



- 학습률만 변경 · 실제 평가 보상 비교

변경 : α=0.05, 0.2, 0.4, 0.8
고정 : E=10,000, ε=0.1, γ=0.9

SARSA 의 평가 할인 보상 G:
0.395, 0.392, 0.387, 0.310
기본 α=0.8 보다 작은 α 에서 높게 관찰 .

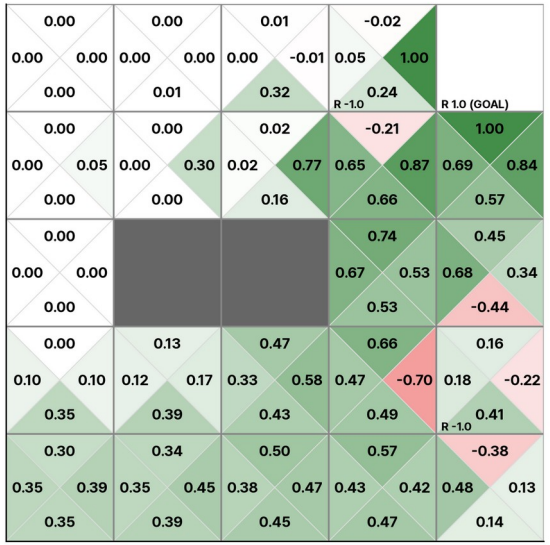
Q-Learning 의 평가 할인 보상 G:
0.404, 0.411, 0.409, 0.410
네 조건에서 비슷한 평균 보상을 관찰 .

평가 ε=0.1, γ=0.9 로 동일하게 고정 .

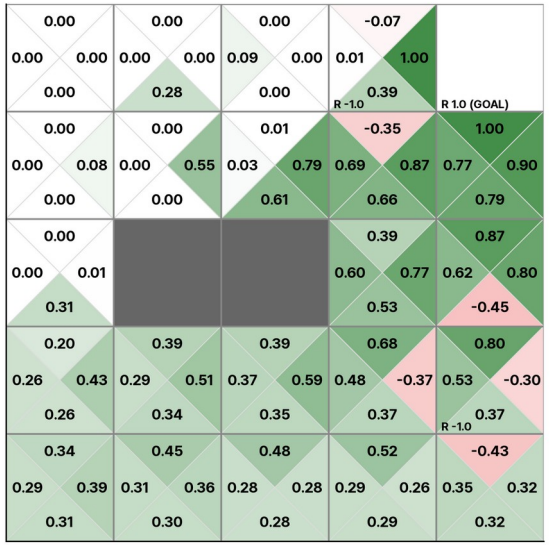
CBNU

SARSA · α 어블레이션 · 시드 0

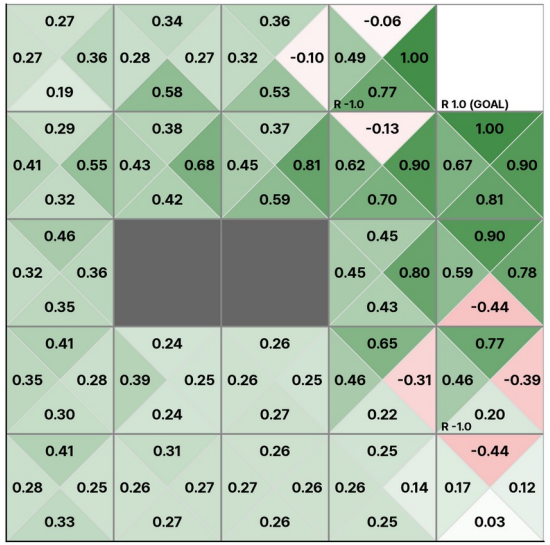
α=0.05



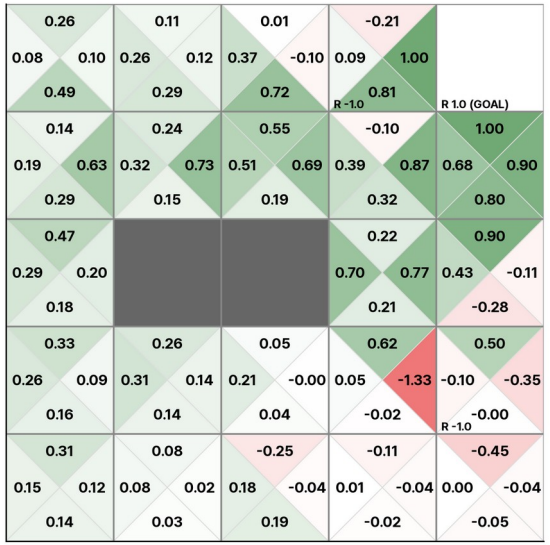
α=0.2



α=0.4



α=0.8



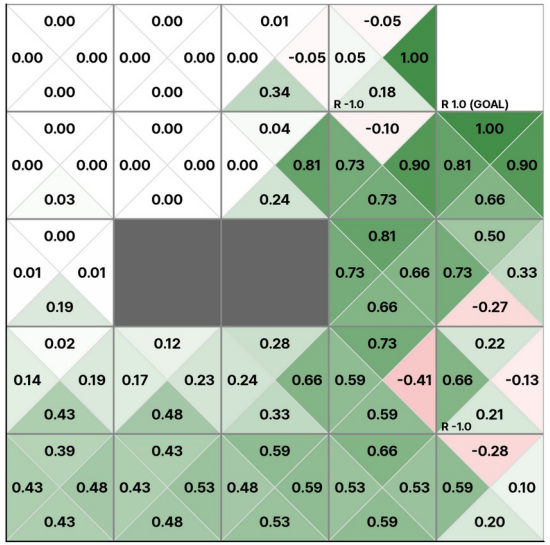
- 작은 α 에서 기본 설정보다 높은 평가 보상 관찰

- 시작점 최대 Q (30 개 시드 평균): 0.396 / 0.403 / 0.399 / 0.340
- 평가 보상 G: 0.395 / 0.392 / 0.387 / 0.310 · 평가 ε=0.1, γ=0.9

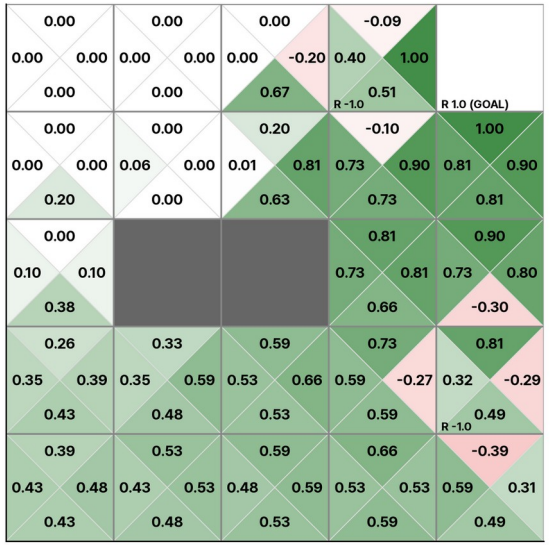
CBNU

Q-Learning · α 어블레이션 · 시드 0

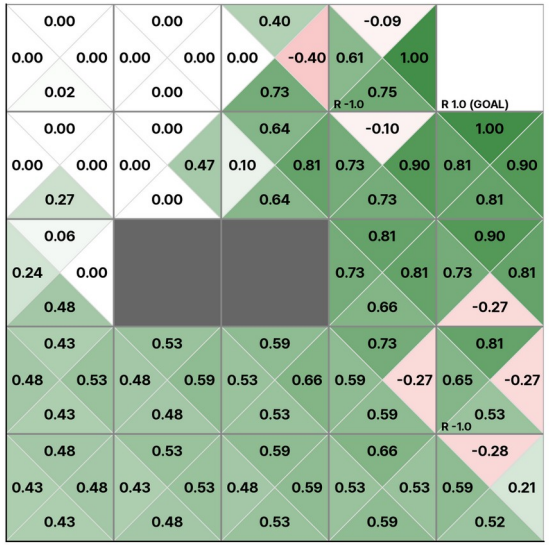
α=0.05



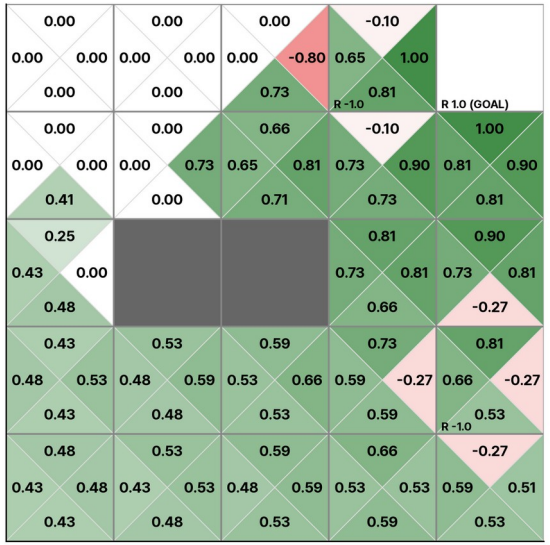
α=0.2



α=0.4



α=0.8

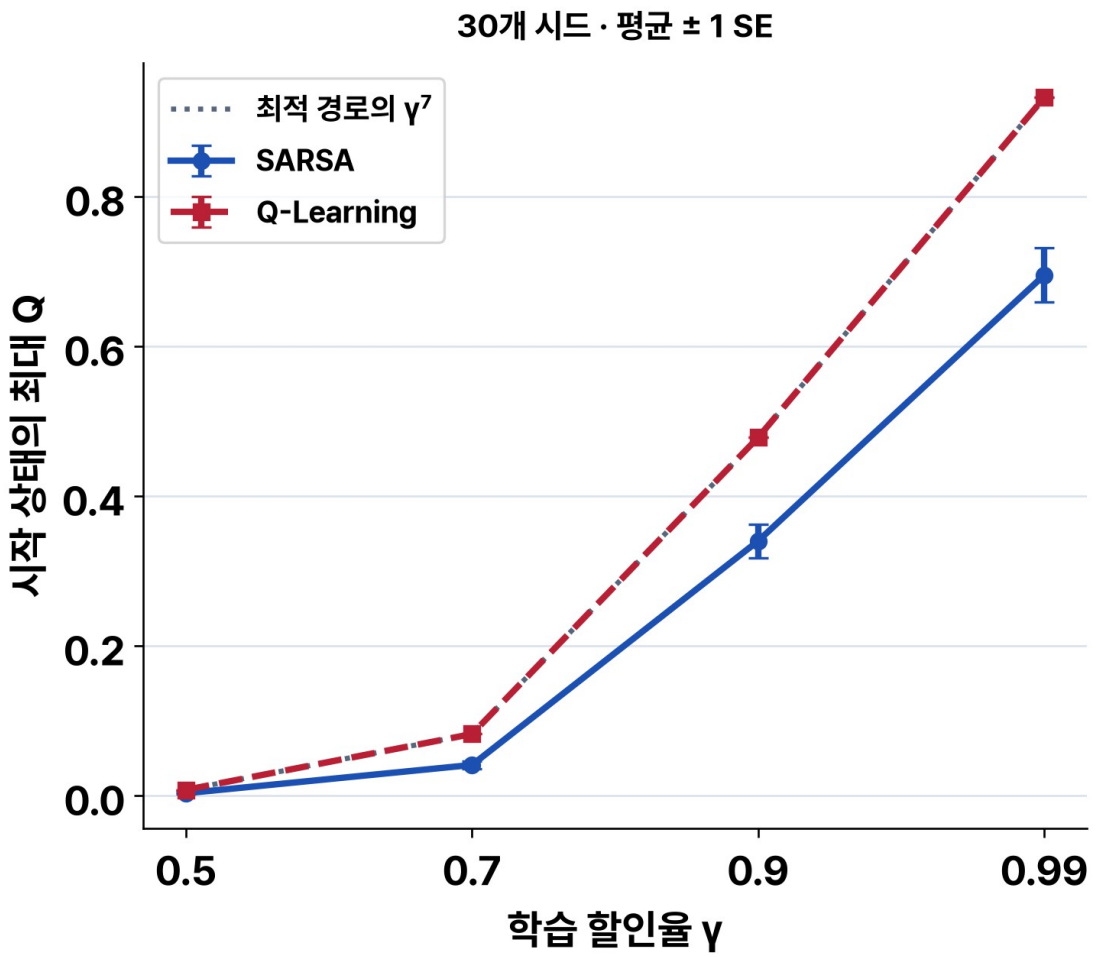


- 네 학습률에서 비슷한 평균 평가 보상 관찰

- 시작점 최대 Q (30 개 시드 평균): 0.478 / 0.478 / 0.478 / 0.478
- 평가 보상 G: 0.404 / 0.411 / 0.409 / 0.410 · 평가 ε=0.1, γ=0.9

CBNU

γ · 가치 · 정책 어블레이션



- **할인율만 변경 · 미래 보상 크기**

변경 : γ=0.5, 0.7, 0.9, 0.99
고정 : E=10,000, ε=0.1, α=0.8

Q-Learning 의 시작점 최대 Q:
0.0078, 0.0824, 0.4783, 0.9321
8-step 최적 경로의 γ^7 와 일치 .

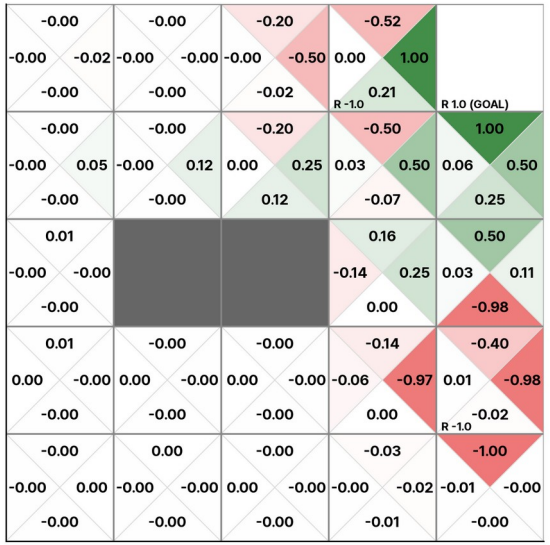
SARSA 평균 최대 Q:
0.0033, 0.0411, 0.3401, 0.6951

큰 Q 만으로 좋은 정책이라 볼 수 없음 .
정책 보상은 평가 γ=0.9 로 비교 .

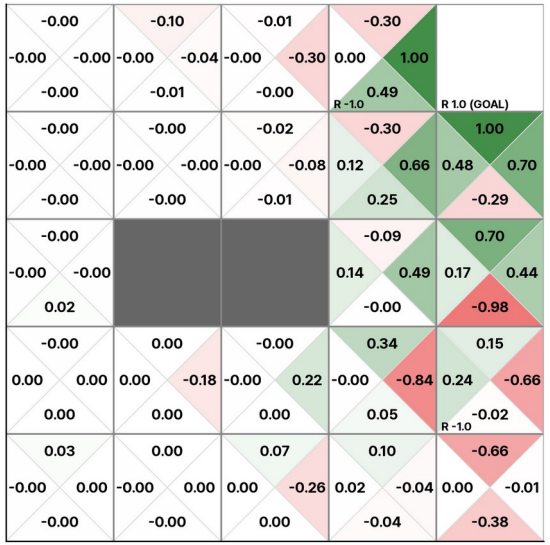
CBNU

SARSA · γ 어블레이션 · 시드 0

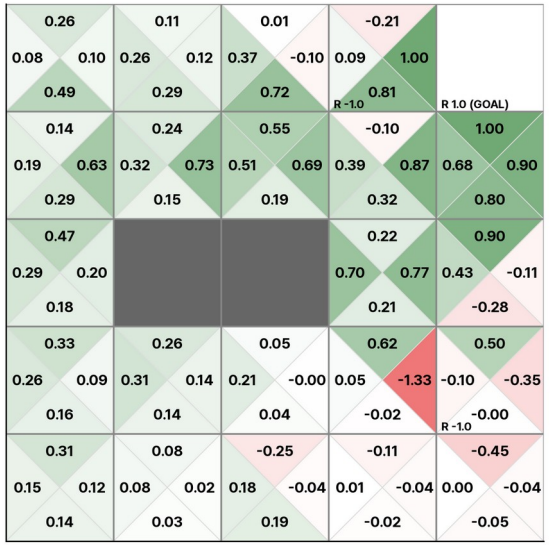
γ=0.5



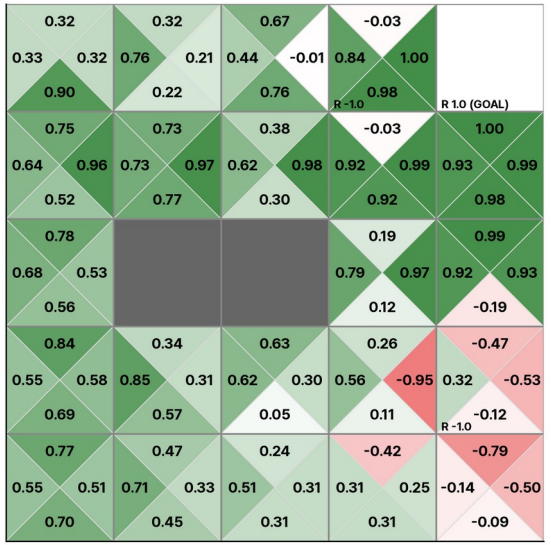
γ=0.7



γ=0.9



γ=0.99



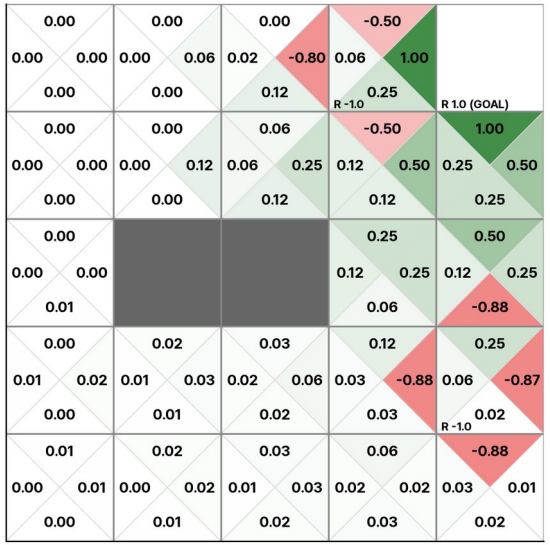
- **Q 의 크기는 증가하지만 평가 보상은 단조 증가하지 않음**

- 시작점 최대 Q (30 개 시드 평균): 0.0033 / 0.0411 / 0.3401 / 0.6951
- 평가 보상 G: 0.234 / 0.230 / 0.310 / 0.261 · 평가 ε=0.1, γ=0.9

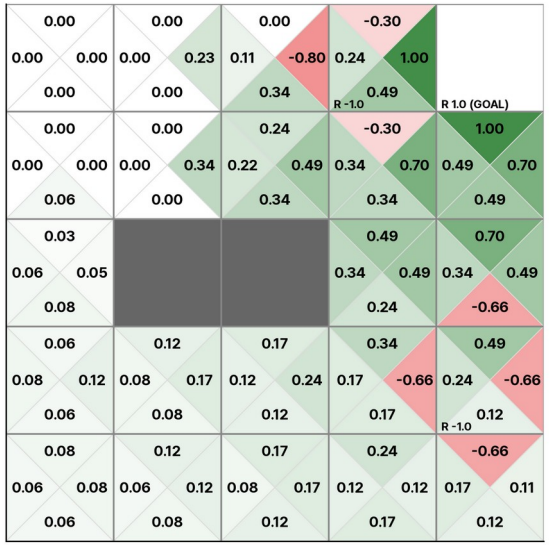
CBNU

Q-Learning · γ 어블레이션 · 시드 0

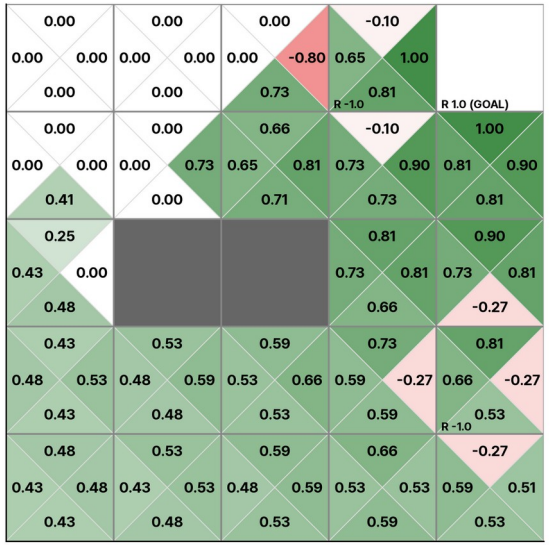
γ=0.5



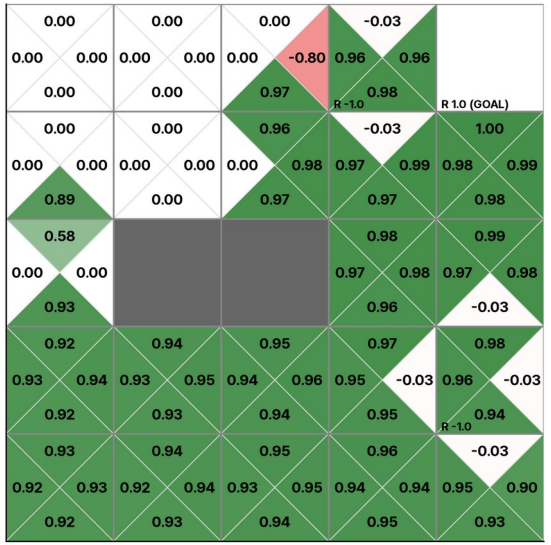
γ=0.7



γ=0.9



γ=0.99

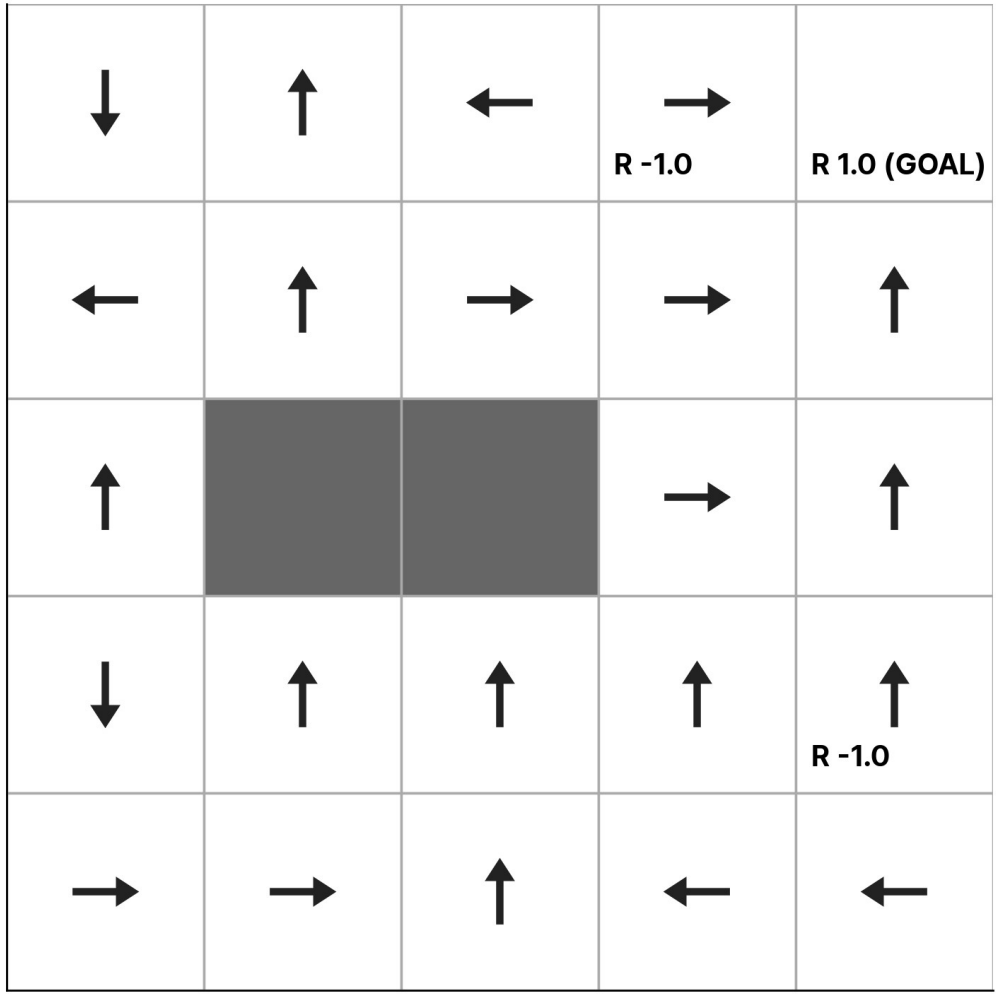


- **시작점 Q 는 γ^7 · 평가 보상은 약 0.41 유지**

- 시작점 최대 Q (30 개 시드 평균): 0.0078 / 0.0824 / 0.4783 / 0.9321
- 평가 보상 G: 0.412 / 0.411 / 0.410 / 0.410 · 평가 ε=0.1, γ=0.9

CBNU

SARSA · 순환 사례



- 기본 설정의 seed 1

시작점에서 (4 행 , 3 열) 로 이동 .
이 칸의 최대 Q 행동은 위쪽 .
위쪽 (3 행 , 3 열) 은 장애물임 .

위 행동 Q = 0.009138
왼쪽 행동 Q = 0.009119
아래 Q = −0.003636
오른쪽 Q = −0.064862

ε=0 에서는 제자리 이동을 반복함 .
ε>0 에서는 무작위 행동으로 탈출 가능 .
따라서 두 평가 결과가 달라질 수 있음 .

SARSA · 어블레이션 결과 종합

실험 항목	관찰한 결과	해석
Episode	G: 0.288 → 0.310	추가 학습 후에도 변동
ε	Q: 0.411 → 0.013	탐험 손실을 가치에 반영
α	α=0.05 의 G: 0.395	기본 G=0.310 보다 높음
γ	γ=0.9 의 G: 0.310	Q 크기와 보상을 구분
기본 정책	최적 행동 일치 69.1%	일부 상태에서 순환 관찰

• SARSA · 실제 선택한 다음 행동의 Q 를 갱신 목표에 사용

- 각 변수만 하나씩 변경 · 평가 ε=0.1, γ=0.9 고정 · 수치는 30 개 시드 평균
- 높은 고정 α 에서 정책 변동 관찰 · 작은 α 의 평가 보상이 더 높게 관찰됨

Q-Learning · 어블레이션 결과 종합

실험 항목	관찰한 결과	해석
Episode	G: 0.402 → 0.410	전체 상태의 정책 개선
ε	ε=0.3 의 행동 일치 100%	탐험으로 방문 범위 확대
α	G: 0.404 ~ 0.411	평가 보상 차이가 작음
γ	시작점 Q 는 γ^7 와 일치	평가 G 는 약 0.41 유지
기본 정책	최적 행동 일치 92.0%	시작점 Q=0.4783

- Q-Learning · 다음 상태의 최대 Q 를 갱신 목표에 사용

- 각 변수만 하나씩 변경 · 평가 ε=0.1, γ=0.9 고정 · 수치는 30 개 시드 평균
- 시작점 가치와 전체 상태의 학습은 구분 · 최적 행동 일치는 Q* 의 동률 행동도 인정

결론

- Q-Learning 은 최적 행동 가치를 목표로 학습
  기본 설정의 시작점 Q=0.4783 · 학습 ε 가 커지면 방문 범위가 확대됨 .

- SARSA 는 탐험 행동의 손실을 가치에 반영
  기본 α=0.8 보다 작은 α 에서 평가 보상이 높게 관찰됨 .

- 정책은 실제 보상과 상태별 행동 선택으로 비교
  기본 설정의 최적 행동 일치 : SARSA 69.1%, Q-Learning 92.0%.

- 같은 어블레이션 조건끼리 Q· 보상 · 정책을 종합
  γ 가 다르면 Q 의 크기도 달라짐 · 평가 ε=0.1, γ=0.9 로 고정하여 비교 .